

绪论

- 贝叶斯学派的最基本的观点是:任一个未知量 θ 都可看作一个随机变量,应该用一个概率分布去描述对 θ 的未知状况。这个概率分布是在抽样前就有的关于 θ 的先验信息的概率称述。
- 似然函数属于联合密度函数, 综合了总体信息和样本信息

$$L(\theta') = p(X|\theta') = \prod_{i=1}^n p(x_i|\theta') \quad (1)$$

- 贝叶斯公式的密度函数形式与离散形式, 其中 θ 的条件分布称为 θ 的后验分布, 集中了总体、样本和先验等三种信息中有关 θ 的一切信息, 排除了与之无关的信息。一般先验分布 $\pi(\theta)$ 反映人们抽样前的认识, 通过抽样信息(总体信息和样本信息)对先验进行调整形成后验分布。

$$\pi(\theta|\mathbf{x}) = \frac{p(\mathbf{x}|\theta)\pi(\theta)}{h(\mathbf{x}, \theta)} = \frac{p(\mathbf{x}|\theta)\pi(\theta)}{\int_{\Theta} p(\mathbf{x}|\theta)\pi(\theta)d\theta} \quad (2)$$

$$\pi(\theta_i|x) = \frac{p(x|\theta_i)\pi(\theta_i)}{\sum_j p(x|\theta_j)\pi(\theta_j)} \quad (3)$$

- 贝叶斯假设, 对无信息时, 可认为 θ 在区间(0,1)的均匀分布

$$\pi(\theta) = \begin{cases} 1, 0 < \theta < 1 \\ 0, \text{其他场合} \end{cases} \quad (4)$$

- 重要分布

- 二项分布 $B(n, p)$: 重复 n 次独立的伯努利试验, 每次试验的成功概率为 p , 当试验次数为1时, 二项分布服从0-1分布, 其分布为: $P(X = k) = C_n^k p^k (1-p)^{n-k}$, 常用于观察单位只能具有相互对立的一种结果的猜测活动。

- 指数分布: 描述泊松过程中的事件之间的时间的概率分布, 即事件以恒定平均速率连续且独立地发生的过程, 具有无记忆的关键性质。常用于描述对发生的缺陷数或系统故障数的测量结果, 但不能作为机械零件功能参数的分布规律。密度函数为: $f(x) = \lambda e^{-\lambda x}; x > 0$

- 泊松分布 $P(\lambda)$: 适合于描述单位时间内随机事件发生的次数。概率函数为:

$$P(X = k) = \frac{\lambda^k}{k!} e^{-\lambda}; k=0,1,\dots \text{当二项分布的} n \text{很大而} p \text{很小时, 泊松分布可作为二项分布的近似, 其中} \lambda \text{为} np。$$

- 贝塔分布, 也称B分布, 定义在(0,1)区间的连续概率分布, 其概率密度函数为:

$$f(x; \alpha, \beta) = \frac{\Gamma(\alpha+\beta)}{\Gamma(\alpha)\Gamma(\beta)} x^{\alpha-1} (1-x)^{\beta-1} = \frac{1}{B(\alpha, \beta)} x^{\alpha-1} (1-x)^{\beta-1}, \text{其中贝塔函数}$$

$$B(\alpha, \beta) = \int_0^1 x^{\alpha-1} (1-x)^{\beta-1} dx = \frac{\Gamma(\alpha)\Gamma(\beta)}{\Gamma(\alpha+\beta)}, \Gamma \text{为伽马函数}$$

$$\Gamma(x) = \int_0^{+\infty} t^{x-1} e^{-t} dt; (x > 0), \text{贝塔分布的核为} \theta^{\alpha-1} (1-\theta)^{\beta-1} (\text{注意区分二项分布的核} \theta^x (1-\theta)^{n-x} \text{中} x \text{为变量, 贝塔分布中} \theta \text{是变量})$$

- 伽马分布 $Ga(\alpha, \lambda)$, 其中 $\alpha > 0$ 为形状参数, $\lambda > 0$ 为尺度参数, 其密度函数为

$$p(x|\alpha, \lambda) = \frac{\lambda^\alpha}{\Gamma(\alpha)} x^{\alpha-1} e^{-\lambda x}, \text{通过此可以得到} Y = X^{-1} \text{的密度函数:}$$

$$p(y|\alpha, \lambda) = \frac{\lambda^\alpha}{\Gamma(\alpha)} \frac{1}{y^{\alpha+1}} e^{-\frac{\lambda}{y}}, \text{称为倒伽马分布记为} IGa(\alpha, \lambda)$$

- 正态分布 $N(\mu, \sigma^2)$: 其概率函数为 $f(x) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$

- 指数分布簇

- 形如 $f_X(x|\theta) = h(x) g(\theta) \exp[\eta(\theta) \cdot T(x)]$

- 包含如正态分布、多项式分布、泊松分布、伽马分布、指数分布、贝塔分布和 *Dirichlet* 分布等

共轭先验

- 设 θ 是总体分布中的参数(或参数向量), $\pi(\theta)$ 是 θ 的先验密度函数,假如由抽样信息算得的后验密度函数与 $\pi(\theta)$ 有**相同的函数形式**,则称 $\pi(\theta)$ 是 θ 的(自然)**共轭先验分布**。通过这种方式计算得到的后验分布的一些参数可以很好解释。共轭先验分布的选区是由似然函数所含的 θ 因式所决定,即选与似然函数(θ 的函数)具有相同核的分布作为先验分布。
 - 正态**均值**(方差已知)的共轭先验分布是正态分布。可以理解为:后验均值是在先验均值与样本均值间采取折衷方案,在处理正态分布时,方差的倒数发挥着重要作用,并称其为**精度**,则**后验分布的精度是样本均值分布的精度与先验分布精度之和**,增加样本量 n 或减少先验分布方差都有利于提高后验分布的精度。

先验知识 $\theta \sim N(\mu, \tau^2)$ 总体分布 $x \sim N(\theta, \sigma^2)$ 样本 $\bar{x}, \sigma_0^2 = \frac{\sigma^2}{n}$ (5)

后验知识 $\pi(\theta|\mathbf{x}) \sim N(\mu_1, \tau_1^2)$

$$\mu_1 = \frac{\frac{\mu}{\tau^2} + \frac{\bar{x}}{\sigma_0^2}}{\frac{1}{\tau^2} + \frac{1}{\sigma_0^2}} \tag{6}$$
$$\frac{1}{\tau_1^2} = \frac{1}{\tau^2} + \frac{1}{\sigma_0^2}$$

- 二项分布的成功概率 θ 的共轭先验分布是贝塔分布

先验 $\theta \sim Be(\alpha, \beta)$ 总体 $X \sim b(n, \theta)$ (7)

后验 $\pi(\theta|\mathbf{x}) \sim Be(\alpha + x, \beta + n - x)$

$$E(\theta|x) = \frac{\alpha + x}{\alpha + \beta + n} = \frac{n}{\alpha + \beta + n} \frac{x}{n} + \frac{\alpha + \beta}{\alpha + \beta + n} \frac{\alpha}{\alpha + \beta} \tag{8}$$

$$Var(\theta|x) \approx \frac{1}{n} \frac{x}{n} (1 - \frac{x}{n})$$

- 常用共轭先验分布

表 1.3.1 常用共轭先验分布

总体分布	参数	共轭先验分布
二项分布	成功概率	贝塔分布 $Be(\alpha, \beta)$
泊松分布	均值	伽玛分布 $Ga(\alpha, \lambda)$
指数分布	均值的倒数	伽玛分布 $Ga(\alpha, \lambda)$
正态分布(方差已知)	均值	正态分布 $N(\mu, \tau^2)$
正态分布(均值已知)	方差	倒伽玛分布 $IGa(\alpha, \lambda)$

- 在单参数指数族场合,使用共轭先验分布得后验均值一定值于先验均值与样本均值(或样本方差等)之间。
- 后验分布的计算**: 由于 $m(x)$ 不依赖于 θ , 在计算时仅起到正则化因子的作用,
 $\pi(\theta|\mathbf{x}) \propto p(\mathbf{x}|\theta)\pi(\theta)$, 其中各因子提取出仅与 θ 有关的称为核。计算时可以略去与 θ 无关的因子。
- 先验分布的选取**, 应以合理性作为首要原则

确定先验信息

超参数: 先验分布中所含的未知参数称为超参数。无信息先验分布一般不含超参数。

- 确定超参数的估计值

- 利用先验矩（根据历史若干个估计值，进行加工整理，得到相关值，估计值来源一般为专家经验）
 - 利用先验分位数（确定两个分位数，得到方程式，解得相关值）
 - 利用先验矩和先验分位数
- 多参数模型（实际问题中常有多个未知参数，而一般不关注的参数称为讨厌参数）
 - 正态均值与正态方差的(联合)共轭先验分布为**正态-逆伽马分布**记为 $N-IGa(v_n, \mu_n \sigma_n^2)$
- 充分统计量
 - 设 \mathbf{x} 是来自分布函数 $F(x|\theta)$ 的一个样本， $T = T(\mathbf{x})$ 是统计量，假如在给定 $T(\mathbf{x})$ 的条件下， \mathbf{x} 的条件分布与 θ 无关的话，则称该统计量为 θ 的充分统计量。
 - 设 x 为密度函数 $p(x|\theta)$ 的一个样本， $T(\mathbf{x})$ 为 θ 的充分统计量的充要条件是，用样本分布 $p(x|\theta)$ 算得的后验分布与统计量 $T(\mathbf{x})$ 算得的后验分布是相同的。如二维统计量 $T = (\bar{x}, Q)$ 恰好是量 (μ, σ^2) 的充分统计量。
 - 使用充分统计量可以简化数据、降低样本维数，从而简化后验分布的计算。

贝叶斯估计

- 条件方法

后验分布是在样本 \mathbf{x} 给定下 θ 的条件分布，基于后验分布的统计推断就意味着只考虑已出现的数据（样本观察值），而认为 未出现的数据与推断无关，这一重要的观点被称为“条件观点”，基于这种观点提出的统计推断方法被称为**条件方法**。

贝叶斯估计

- 从后验分布中选用某个特征量作为 θ 的估计。使后验密度达到最大的值 θ_{MG} 称为最大后验估计；后验分布的中位数 θ_{Me} 称为 θ 的后验中位数估计；后验分布的期望值 θ_E 称为 θ 的后验期望估计，这三个估计也都称为 θ 的**贝叶斯估计**，记为 θ_B ，在不引起混乱时也记为 θ_0 。实际中，一般采用后验期望估计作为贝叶斯估计。
 - 估计的误差。取后验均值可使后验均方差达到最小。

定义 2.2.2 设参数 θ 的后验分布 $\pi(\theta|\mathbf{x})$ ，贝叶斯估计为 $\hat{\theta}$ ，则 $(\theta - \hat{\theta})^2$ 的后验期望

$$MSE(\hat{\theta}|\mathbf{x}) = E^{\pi|\mathbf{x}}(\theta - \hat{\theta})^2$$

称为 $\hat{\theta}$ 的后验均方差，而其平方根 $[MSE(\hat{\theta}|\mathbf{x})]^{\frac{1}{2}}$ 称为 $\hat{\theta}$ 的后验标准误，其中符号 $E^{\pi|\mathbf{x}}$ 表示用条件分布 $\pi(\theta|\mathbf{x})$ 求期望，当 $\hat{\theta}$ 为 θ 的后验期望 $\hat{\theta}_E = E(\theta|\mathbf{x})$ 时，则

$$MSE(\hat{\theta}_E|\mathbf{x}) = E^{\pi|\mathbf{x}}(\theta - \hat{\theta}_E)^2 = \text{Var}(\theta|\mathbf{x})$$

称为后验方差，其平方根 $[\text{Var}(\theta|\mathbf{x})]^{\frac{1}{2}}$ 称为后验标准差。

- 柯西分布 期望不存在

区间估计

对于区间估计问题，贝叶斯方法具有处理方便和含义清晰的优点，而经典方法寻求的置信区间常受到批评。

- 可信区间：

设参数 θ 的后验分布为 $\pi(\theta|x)$ ，给定样本 x 和概率 α ($0 < \alpha < 1$)，若存在这样两个统计量 θ_U, θ_L ，使得 $P(\theta_L \leq \theta \leq \theta_U|x) > 1 - \alpha$ ，则称区间 $[\theta_U, \theta_L]$ 为 θ 的可信水平为 $1 - \alpha$ 的贝叶斯可信区间，即参数 θ 的 $1 - \alpha$ 的可信区间。仿照经典方法，可以得到 $1 - \alpha$ 的单侧可信下限和 $1 - \alpha$ 的单侧可信上限。

- 贝叶斯方法可信区间的寻求，较经典统计方法更简单。
- 经典统计求得的是置信区间，而贝叶斯得到的是可信区间，可信区间更符合理解和解释。
- 最大后验密度(HPD)可信区间

区间长度最短，并把具有最大后验密度的点都包含在区间内，而区间外的点上的后验密度函数值不超过区间内的后验密度函数值

- 若后验密度函数是单峰对称的，则 $(1 - \alpha)$ HPD可信空间为等尾可信区间，单峰不对称需要计算机辅助计算；多峰则可能出现可信区间不连续的情况。
- PS：当后验密度函数出现多峰时，常常是由于先验信息与抽样信息不一致引起的，而共轭先验分布大多是单峰的，这必导致后验分布也是单峰的，它可能会掩盖这种不一致信息，故而要慎重对待和使用共轭先验分布。

假设检验

获得后验分布后，计算两个假设 H_0 与 H_1 的后验概率，然后比较两者的大小，即观察后验概率比 α_0/α_1 ，从中选择最大概率的一方；但当两者相接近时需要进一步抽样或搜集信息。此种方法可推广到三个及以上的假设状况。

- 贝叶斯因子，既依赖于样本数据 x ，还依赖于先验分布 π ，这会减弱先验的影响，突出数据的影响；贝叶斯因子体现了数据支持某假设的程度。贝叶斯因子对样本信息变化的反应是灵敏的，而对先验信息变化的反应是迟钝的。

$$B^\pi(x) = \frac{\text{后验机会比}}{\text{先验机会比}} = \frac{\alpha_0/\alpha_1}{\pi_0/\pi_1} = \frac{\alpha_0\pi_1}{\pi_0\alpha_1} \quad (9)$$

- 简单对简单（参数假设为特定值）

$$B^\pi(x) = \frac{\alpha_0\pi_1}{\pi_0\alpha_1} = \frac{p(x|\theta_0)}{p(x|\theta_1)} \quad (10)$$

- 复杂对复杂（参数假设为特定区间，使用 $g(\theta)$ 约束 θ 的范围表示 θ 的分布情况，特别的取两个区间 θ 的极大似然估计代替 $g(\theta)$ 的加权结果可以得到经典统计的似然比统计量）

$$B^\pi(x) = \frac{\alpha_0\pi_1}{\alpha_1\pi_0} = \frac{\int_{\Theta_0} p(x|\theta)g_0(\theta)d\theta}{\int_{\Theta_1} p(x|\theta)g_1(\theta)d\theta} = \frac{m_0(x)}{m_1(x)}$$

- 简单对复杂（综合前两种情况的思维，将特定值转化为以特定值附近区间）

$$B^\pi(x) = \frac{\alpha_0\pi_1}{\alpha_1\pi_0} = \frac{p(x|\theta_0)}{m_1(x)}$$

由于此类情况的贝叶斯因子计算简单，可以使用其计算得到 θ 的后验分布：

$$\pi(\Theta_0|x) = \left[1 + \frac{1 - \pi_0}{\pi_0} \frac{1}{B^\pi(x)} \right]^{-1}$$

- 以上的三种可以拓展到多重假设问题，PS: 针对现实问题，需要根据已知的信息和分布特定，设定总体分布和先验函数。
- 预测（对随机变量未来观察值做出统计推断，一般先获得变量分布，再取期望、中位数、众数、一定区间等作为预测值）预测值的方差一般大于实测值的方差。
 - 如果无样本观察数据，则使用先验分布获得随机变量 x 的边缘分布 $m(x)$ 。
 - 如果有样本观察数据，则使用先验分布求得后验分布，再计算随机变量 x 的后验预测分布 $m(x|\mathbf{x})$ 。

$$m(x|\mathbf{x}) = \int_{\theta} p(x|\theta)\pi(\theta|\mathbf{x})d\theta$$

- 如果有样本观察数据，并估计同参数的另一个随机变量，则使用先验分布获得随机变量 z 的后验预测分布 $m(z|\mathbf{x})$ 。

$$m(z|\mathbf{x}) = \int_{\theta} g(z|\theta)\pi(\theta|\mathbf{x})d\theta$$

- 似然原理 当 x 的样本值给出时，似然函数为 $L(\theta) = p(x|\theta) = \prod_{i=1}^n p(x_i|\theta)$ 这是一个关于 θ 的函数，使似然函数在参数空间取最值的 $\hat{\theta}$ 称为最大似然估计。
 - 有了观测值后，似然函数 $L(\theta)$ 包含了所有与试验有关的 θ 的信息；
 - 如果两个似然函数成比例，比例函数与 θ 无关，则两者包含 θ 的信息相同

先验分布的确定

- 主观概率(人们根据经验对一个事件发生可能性的个人信念，对取值范围是离散时更有效)
 - 对立事件比较
 - 专家意见（询问专家时需要设计好问题，并对专家有一定的了解便于修正形成自己的主观概率，或者向多个专家咨询综合修正）
 - 历史资料
- 利用先验信息（参数空间连续）
 - 等分区间统计各区间的频率，绘制直方图
 - 选定先验密度后再估计超参数
 - 定分度与变分度
- 利用边缘分布 $m(x)$
 - 边缘分布可以看作是混合分布（多个总体加权平均）的推广，如果 $p(x|\theta)$ 已知，则 $m(x)$ 可以反映先验函数的合理性；
 - 把 m^π 作为先验函数 π 的似然函数，通过极大似然法选取 π ，这种方法称为二型极大似然先验。如果先验密度函数形式已知，则求解先验函数中的超参数即可。
 - 矩方法(先验函数形式已知时，利用先验矩和边缘分布矩的关系建立方程寻求超参数的估计值)
- 无信息先验与广义先验分布

贝叶斯决策

- 决策三要素：状态集合、行动集、收益函数 Q
- 行动的容许性：行动集中只存在容许的行动（有选择地可能，有存在地必要）
- 决策准则：悲观准则(max min)、乐观准则(max max)、折中准则（乐观系数）

- 损失函数 $L = \max(Q) - Q$ "该赚却没赚到的钱"。损失函数包含了较多的信息，使用其做决策将更为合理
- 先验期望准则：以收益函数在先验信息下得到的先验期望收益，取最大处为最优行动（与收益函数的原点和单位无关）；或以损失函数在先验信息下得到的先验损失，取最大处为最优行动。两种方式只用到了先验信息，故只能使用正常的先验分布，而不能使用广义先验分布。
- 把损失函数引入贝叶斯统计推断，就构成了贝叶斯决策问题。
- 后验风险准则：损失函数对后验分布的期望称为后验风险 R ，以后验风险最小处为最优行动（和样本有关，故是一个决策函数），此时的决策函数为贝叶斯解。
- 决策函数（从样本到决策的映射）与决策函数类

贝叶斯小结

- 认识到贝叶斯学派的最基本的观点是：**任何一个未知量 θ 都可看作一个随机变量,应该用一个概率分布去描述对 θ 的未知状况。**
- 牢记贝叶斯原理的公式，分清离散与连续的区别和使用情景。

$$\pi(\theta|\mathbf{x}) = \frac{p(\mathbf{x}|\theta)\pi(\theta)}{h(\mathbf{x},\theta)} = \frac{p(\mathbf{x}|\theta)\pi(\theta)}{\int_{\Theta} p(\mathbf{x}|\theta)\pi(\theta)d\theta} \quad (11)$$

- 针对现实问题，需要根据已知的信息和分布特征，把握总体分布和先验函数形式。
- 牢记各种分布的函数的分布函数，核的形式，共轭先验分布，期望与方差，掌握利用似然原理计算后验的超参数，了解区间(0,1)上的均匀分布 $U(0,1)$ 是贝塔分布 $Be(1,1)$ ，从 $U(0,1)$ 中样本的第 k 个顺序量 $x_{(k)} \sim Be(k, n - k + 1)$;

常见分布	概率密度或概率函数	数学期望	方差	共轭先验分布
均匀分布	$f(x) = 1/(b-a), a \leq x \leq b,$	$\frac{a+b}{2}$	$\frac{(b-a)^2}{12}$	a=0 时, b — pareto 分布
二项分布	$P(X = k) = C_n^k p^k (1-p)^{n-k}$	np	$np(1-p)$	p—贝塔分布
泊松分布	$P(X = k) = \frac{\lambda^k}{k!} e^{-\lambda}$	λ	λ	λ —伽马分布
指数分布	$f(x) = \lambda e^{-\lambda x}; x > 0,$ 即 $Ga(1, \lambda)$	$1/\lambda$	$1/\lambda^2$	λ —伽马分布, $1/\lambda$ —逆伽马分布
正态分布	$f(x) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$	μ	σ^2	μ —正态分布; σ^2 —逆伽马分布
贝塔分布	$f(x; \alpha, \beta) = \frac{\Gamma(\alpha+\beta)}{\Gamma(\alpha)\Gamma(\beta)} x^{\alpha-1} (1-x)^{\beta-1}$	$\alpha/(\alpha+\beta)$	$\frac{\alpha\beta}{(\alpha+\beta)^2(\alpha+\beta+1)}$	
伽马分布	$p(x \alpha, \beta) = \frac{\beta^\alpha}{\Gamma(\alpha)} x^{\alpha-1} e^{-\beta x}, x > 0$	α/β	α/β^2	
逆伽马分布	$p(y \alpha, \beta) = \frac{\beta^\alpha}{\Gamma(\alpha)} (1/y)^{\alpha+1} e^{-\beta/y}, y > 0$	$\beta/(\alpha-1)$	$\frac{\beta^2}{(\alpha-1)^2(\alpha-2)}$	
卡方分布	即 $Ga(n/2, 1/2)$, n为自由度	n	$2n$	

- 正态分布作正态分布均值的共轭先验的性质（方差的倒数——精度可以看作是 先验与样本精度的和）

$$\text{先验 } \theta \sim N(\mu, \tau^2) \text{ 总体分布 } x \sim N(\theta, \sigma^2) \text{ 样本 } \bar{x}, \sigma_0^2 = \frac{\sigma^2}{n} \quad (12)$$

$$\text{后验 } \pi(\theta | \mathbf{x}) \sim N(\mu_1, \tau_1^2)$$

$$\mu_1 = \frac{\frac{\mu}{\tau^2} + \frac{\bar{x}}{\sigma_0^2}}{\frac{1}{\tau^2} + \frac{1}{\sigma_0^2}}$$

$$\frac{1}{\tau_1^2} = \frac{1}{\tau^2} + \frac{1}{\sigma_0^2}$$

- 贝塔分布作二项分布成功概率的共轭先验的性质（ α β 分别可以看作实验成功次数与不成功次数的累积）

$$\text{先验: } \theta \sim Be(\alpha, \beta) \text{ 总体: } X \sim b(n, \theta) \text{ 样本: } x \quad (13)$$

$$\text{后验 } \pi(\theta | \mathbf{x}) \sim Be(\alpha + x, \beta + n - x)$$

- 伽马分布对泊松分布强度的共轭先验的性质 (α, β 可以看作泊松分布样本信息和与样本量的累计)

$$\begin{aligned} \text{先验: } \theta &\sim Ga(\alpha, \beta) \quad \text{总体: } P(x = x) = \frac{\theta^x}{x!} e^{-\theta} \quad \text{样本: } \mathbf{x} \quad (14) \\ \text{后验: } \theta &\sim Ga(n\bar{x} + \alpha, n + \beta) \end{aligned}$$

- 伽马分布对指数分布的共轭先验的性质 (β, α 可以看作泊松分布样本信息和与样本量的累计)

$$\begin{aligned} \text{先验: } \theta &\sim Ga(\alpha, \beta) \quad \text{总体: } X \sim Exp(\lambda) \quad \text{样本: } \mathbf{x} \quad (15) \\ \text{后验: } \theta &\sim Ga(\alpha + n, \beta + n\bar{x}) \end{aligned}$$

- 认识到后验函数是样本信息与先验信息的综合，在后验的期望和方差中可以体现为加权或整合的形式，理解方差倒数作为精度的思维。
- 掌握常用的先验函数中参数的求法：ML二型先验法和矩方法（利用边缘函数 $m(x)$ 极值或矩关系）；
- 掌握常用的贝叶斯估计：后验期望估计（后验函数的期望）和最大后验估计（得到后验函数，求导取极值点）的求法。
- 区分样本均值的方差和样本的方差的不同，区分贝叶斯估计中后验均方差与后验方差、后验标准误与后验标准差的不同。
- 理解假设检验中贝叶斯因子可以体现样本数据对原假设的支持程度

假设的形式	Bayes因子	说 明
简单假设对简单假设	$B = \frac{\alpha_0 \pi_1}{\alpha_1 \pi_0} = \frac{p(\mathbf{x} \theta_0)}{p(\mathbf{x} \theta_1)}$	B的大小表示样本支持 θ_0 的程度。
复杂假设对复杂假设	$B = \frac{\alpha_0 \pi_1}{\alpha_1 \pi_0} = \frac{m_0(\mathbf{x})}{m_1(\mathbf{x})}$	B可看作 Θ_0 与 Θ_1 上的加权似然比，它部分地消除了先验分布的影响，而强调了样本观察值的作用。
简单假设对复杂假设	$B = \frac{\alpha_0 \pi_1}{\alpha_1 \pi_0} = \frac{p(\mathbf{x} \theta_0)}{m_1(\mathbf{x})}$	在实际应用中，可以先计算B，再计算后验概率： $\alpha_0 = \left[1 + \frac{1 - \pi_0}{\pi_0} \frac{1}{B} \right]^{-1}$

- 理解利用贝叶斯决策的方法来实现假设检验时，引入了贴合实际情况和目标的损失函数，从而提供了一个显著性水平的合理选取方法。
- 掌握收益函数 $Q(\theta, a)$ 和损失函数 $L(\theta, a)$ 的计算方式，区分先验期望损失与后验风险 $R(a | \mathbf{x})$ （损失函数 $L(\theta, a)$ 对后验分布 $\pi(\theta | \mathbf{x})$ 的期望）与完全信息期望EVPI（理想）
- 区分估计中的贝叶斯估计和决策中的贝叶斯估计的异同，在贝叶斯推断中定义了贝叶斯估计的概念，并没有结合实际的场景提出选取的方法而一般选取后验期望估计，决策中引入决策函数结合了具体的场景，并在行动集空间与参数空间同为某个实数集时，提出选取估计的依据为后验风险准则。
- 掌握计算贝叶斯决策中常用损失函数下的贝叶斯估计的方法：平方损失下的（均值或其变形）、绝对值损失下的（分位点）。 $\frac{dR}{d\delta} = \frac{dE(L(\theta, \delta) | \mathbf{x})}{d\delta} = 0$

部分练习习题：1.2、1.4、1.8、**1.11**、1.13、1.19、**2.2**、2.5、**2.8**、**2.10**、3.12、5.12、例1.3.1

参考答案：<https://wenku.baidu.com/view/4643d9c180eb6294dd886c66?fromShare=1>

贝叶斯网络

- 贝叶斯网络是用来表示变量间连接概率的图形模式，能表示复杂联合概率分布的紧凑表示形式，它提供了一种自然的表示因果信息的方法，用来发现数据间的潜在关系。在这个网络中，用节点表示变量，有向边表示变量的依赖关系，并使用条件概率表（CPT）来描述联合概率分布。

利用贝叶斯方法学习权重

贝叶斯方法考虑的权重空间（即权重的整个解空间上许多解）上权重的概率分布，通过先验和观测的新的数据，不断更新后验概率，使得权重逐渐集中到权重空间的局部上。

- 先验选择：一般选择性质较好的高斯分布
- 贝叶斯巧妙的将最大似然技术（误差平方和最小）和正则化（权重衰减）技术结合起来。当数据集较大，随着训练进行，上式中样本信息会随着增大并成为主导，同时先验的重要性逐渐减弱。当数据集较小的时候，先验在决定解就会起很重要作用。
- 很多情况下，积分是很难进行的，就需要通过近似方法来求解。如使用泰勒展开保留2阶项来近似计算。

贝叶斯的简单运用

- [拼写检查](#)
- 邮件分类